



Master 2 Ingénierie des Données et Evaluations Econométriques

**Projet de Machine Learning : Prédiction des prix des maisons à
Londres**

Matière : Algorithmie et programmation

Réalisé par :

Halima KADDAR

Sara KHALLOUD

Ikram ELFAHLI

Enseignant :

Axel-Cleris GAILLOTY

Année universitaire : 2025-2026

PLAN :

I. Introduction	3
II. Description du jeu de données	3
III. Architecture du projet	4
1. Structure générale.....	4
1.1. training.py	5
1.2. objets.py	5
1.3. formulaire.py	5
1.4. model_helper.py	5
1.5. app.py	5
IV. Déroulement de l'implémentation.....	6
2. Analyse du jeu de données	6
3. Nettoyage et préparation des données	6
4. Encodage des variables catégorielles	6
5. Séparation des données	6
6. Entraînement des modèles.....	7
7. Évaluation des performances	7
8. Sauvegarde des modèles.....	7
9. Développement de l'application Streamlit.....	8
10. Intégration des modèles dans l'application.....	8
V. Conclusion :	8

I. Introduction

L'estimation de la valeur d'un bien immobilier représente une problématique importante pour de nombreux acteurs du marché, notamment les particuliers, les agences immobilières et les investisseurs. Dans un contexte où les prix de l'immobilier sont influencés par de multiples facteurs, l'utilisation des techniques de Machine Learning offre la possibilité de développer des modèles capables d'analyser ces informations et de produire des estimations fiables.

L'objectif de ce projet est de concevoir une application de prédiction des prix immobiliers pour des logements situés à Londres. À partir de caractéristiques descriptives telles que la surface habitable, le nombre de chambres, le quartier, le type de propriété ou encore les équipements disponibles, l'application est en mesure d'estimer automatiquement la valeur d'un bien.

La réalisation de ce projet s'inscrit dans une démarche complète de science des données. Elle comprend l'étude et la préparation du jeu de données, le traitement des informations manquantes et des valeurs aberrantes, l'encodage des variables catégorielles, l'entraînement et l'évaluation de plusieurs modèles de régression, ainsi que le déploiement d'une interface utilisateur interactive développée avec Streamlit.

Cette approche permet non seulement d'explorer les performances de différentes méthodes de Machine Learning, mais également de proposer une solution concrète et facilement utilisable pour l'estimation des prix immobiliers.

II. Description du jeu de données

Le dataset de kaagle utilisé contient 1000 observations représentant des logements situés dans différents quartiers de Londres.

- Variables explicatives

Variable	Description
Bedrooms	Nombre de chambres
Bathrooms	Nombre de salles de bain
Square_Meters	Surface du logement
Building_Age	Âge du bâtiment
Floors	Nombre d'étages

Neighborhood	Quartier
Property_Type	Type de propriété
Garage	Présence d'un garage
Garden	Présence d'un jardin
Heating_Type	Type de chauffage
Balcony	Type de balcon
Interior_Style	Style intérieur
View	Vue du logement
Materials	Matériaux principaux
Building_Status	État du bâtiment

- Variable cible

Price : Prix du logement en livres sterling (£).

III. Architecture du projet

Afin de garantir une bonne organisation du code et une séparation claire des responsabilités, le projet a été structuré en plusieurs modules spécialisés.

1. Structure générale

ML/

|

|— training.py

|— model_helper.py

|— objets.py

|— formulaire.py

|— app.py

|— models/

| |— Ridge_Model.pkl

| |— RandomForest_Model.pkl

```
| |— GradientBoosting_Model.pkl
| |— XGBoost_Model.pkl
| |— feature_names.json
|— london_houses.csv
```

1.1.training.py

Ce fichier constitue le cœur du projet. Il assure le prétraitement des données, l'entraînement des modèles de Machine Learning, leur évaluation ainsi que leur sauvegarde dans le dossier *models*.

1.2.objets.py

Ce module contient les structures de données utilisées par l'application :

- UserInput : représente les données saisies par l'utilisateur ;
- MLInput : représente les données transformées et encodées dans le format attendu par les modèles de Machine Learning.

1.3.formulaire.py

Ce module est chargé de la construction de l'interface de saisie utilisateur.

Il permet de collecter les caractéristiques du logement, vérifier la validité des valeurs saisies et de créer une instance de la classe `UserInput` à partir des informations renseignées.

1.4. model_helper.py

Ce module joue le rôle d'intermédiaire entre les modèles entraînés et l'application utilisateur.

Ses principales fonctions sont : charger les modèles sauvegardés, récupérer la liste des variables attendues par les modèles, gérer la correspondance entre les noms utilisés dans l'application et ceux utilisés lors de l'entraînement et garantir la cohérence des données fournies aux modèles.

1.5.app.py

Ce fichier constitue le point d'entrée principal de l'application.

Il assure les opérations suivantes : affichage de l'interface Streamlit, récupération des données saisies, conversion des données utilisateur en format compatible avec les modèles, chargement du modèle sélectionné, calcul de la prédiction, affichage du prix estimé du logement.

IV. Déroulement de l'implémentation

La réalisation du projet a suivi une démarche progressive permettant de construire un système complet de prédiction immobilière.

2. Analyse du jeu de données

La première étape a consisté à étudier le jeu de données immobilier londonien afin d'identifier : les variables disponibles, la variable cible à prédire, la présence éventuelle de données manquantes, les incohérences et valeurs aberrantes.

Cette phase a permis de mieux comprendre les caractéristiques du marché immobilier représenté dans les données.

3. Nettoyage et préparation des données

Les données ont ensuite été préparées afin d'améliorer leur qualité.

Les traitements réalisés comprennent la suppression des doublons, l'imputation des valeurs manquantes, la suppression des valeurs aberrantes sur le prix et l'application de contraintes métier sur certaines variables.

Cette étape est essentielle pour garantir la fiabilité des modèles de prédiction.

4. Encodage des variables catégorielles

Les algorithmes de Machine Learning ne pouvant pas traiter directement les données textuelles, les variables catégorielles ont été transformées.

Deux techniques ont été utilisées :

- encodage binaire pour les variables Oui/Non ;
- One-Hot Encoding pour les variables possédant plusieurs modalités.

Cette transformation permet aux modèles d'exploiter efficacement les informations qualitatives présentes dans le dataset.

5. Séparation des données

Le jeu de données a été divisé en deux parties : 80 % des données pour l'entraînement et 20 % des données pour les tests.

Cette séparation permet d'évaluer objectivement les performances des modèles sur des données jamais vues pendant l'apprentissage.

6. Entraînement des modèles

Quatre modèles de régression ont été entraînés :

- Ridge Regression ;
- Random Forest Regressor ;
- Gradient Boosting Regressor ;
- XGBoost Regressor.

Ces modèles ont été sélectionnés afin de comparer différentes approches allant des modèles linéaires aux méthodes d'ensemble plus avancées.

7. Évaluation des performances

Les modèles ont été évalués à l'aide de deux métriques :

- Mean Absolute Error (MAE)

Cette métrique mesure l'erreur moyenne commise par le modèle entre la valeur réelle et la valeur prédite.

- Coefficient de détermination (R^2)

Cette métrique indique la proportion de la variance expliquée par le modèle.

Les résultats obtenus montrent que le modèle Gradient Boosting présente les meilleures performances sur le jeu de données étudié.

8. Sauvegarde des modèles

Une fois entraînés, les modèles ont été sauvegardés au format «. pkl ».

Cette sauvegarde permet de réutiliser directement les modèles sans avoir à relancer tout le processus d'entraînement.

La liste des variables utilisées a également été enregistrée dans le fichier « feature_names.json ».

9. Développement de l'application Streamlit

Une interface utilisateur interactive a été développée avec Streamlit.

Cette interface permet à l'utilisateur de renseigner la surface du logement, le nombre de chambres, le nombre de salles de bain, le quartier, le type de propriété, les équipements disponibles, les caractéristiques du bâtiment.

10. Intégration des modèles dans l'application

La dernière étape a consisté à connecter l'interface utilisateur aux modèles entraînés.

Les données saisies sont automatiquement :

- récupérées par le formulaire ;
- converties au format attendu par les modèles ;
- transmises au modèle sélectionné ;
- utilisées pour produire une estimation du prix immobilier.

L'utilisateur obtient ainsi instantanément une prédiction personnalisée du prix du bien immobilier.

V. Conclusion :

Ce projet a permis de concevoir et de développer une application complète de prédiction des prix immobiliers basée sur des techniques de Machine Learning. L'ensemble du processus, depuis la préparation des données jusqu'au déploiement du modèle, a été mis en œuvre afin de reproduire les différentes étapes d'un projet de science des données appliqué à une problématique réelle.

Une attention particulière a été portée à la qualité des données à travers différentes opérations de nettoyage, de traitement des valeurs manquantes et d'encodage des variables catégorielles. Plusieurs modèles de régression ont ensuite été entraînés et évalués afin d'identifier l'approche la plus adaptée à la prédiction des prix immobiliers.

Les résultats obtenus montrent que le modèle **Gradient Boosting Regressor** est celui qui offre les meilleures performances sur le jeu de données étudié, avec une faible erreur de prédiction et un excellent pouvoir explicatif. Ces résultats confirment l'intérêt des méthodes d'ensemble pour la modélisation de phénomènes complexes tels que l'évolution des prix de l'immobilier.